

#Relación entre las horas de estudio y la calificación obtenida en un examen: un análisis mediante regresión lineal simple

##Integrantes:

- Paola Alejandra Cortes Delgado
- Xcaret Geraldine Prieto Torres

El proyecto tiene como propósito analizar la relación existente entre las horas de estudio y la calificación obtenida en un examen mediante la aplicación de un modelo de regresión lineal simple. Para ello, diseñamos y aplicamos una encuesta para recopilar información directamente de estudiantes, con el fin de obtener datos propios que permitieran evaluar si el tiempo dedicado al estudio influye en el rendimiento académico.

A partir de la información recopilada, se desarrolló un análisis estadístico que incluye la construcción del modelo de regresión, la evaluación de su calidad y la elaboración de recomendaciones sustentadas en la evidencia obtenida.

```
import pandas as pd
link= "https://raw.githubusercontent.com/cortespoalalejandra-
dotcom/EstadisticaVerano2026/refs/heads/main/ProyectoIntegrador/Relaci%C3%B3n%20entre%20las%20horas%20de
df=pd.read_csv(link)
df
```

	Edad	Sexo	Semestre_actual	Horas_estudiadas	Calificacion_obtenida
0	21	Femenino	6	8	87
1	24	Masculino	6	1	70
2	27	Femenino	9	4	100
3	21	Masculino	7	3	100
4	23	Masculino	8	3	87
5	22	Femenino	1	2	87
6	26	Femenino	8	6	90
7	21	Masculino	6	2	84
8	17	Femenino	4	2	8
9	21	Masculino	6	4	70
10	17	Femenino	5	5	9
11	17	Femenino	5	5	85
12	17	Femenino	7	6	8
13	16	Femenino	4	1	100
14	21	Femenino	6	1	100
15	20	Femenino	6	2	92
16	21	Masculino	9	2	10
17	14	Femenino	4	1	96
18	21	Femenino	9	6	90
19	22	Femenino	7	2	79
20	21	Masculino	6	4	90
21	23	Femenino	9	5	96
22	20	Femenino	5	2	80
23	22	Femenino	7	5	85
24	19	Masculino	2	1	75
25	18	Masculino	3	1	70
26	22	Masculino	6	3	80
27	19	Masculino	4	2	90
28	22	Masculino	8	4	80
29	15	Femenino	3	1	70
30	20	Masculino	4	2	82
31	23	Femenino	5	4	89
32	17	Femenino	4	3	81
33	20	Masculino	4	2	80

	Edad	Sexo	Semestre_actual	Horas_estudiadas	Calificacion_obtenida
34	19	Masculino	4	3	80
35	19	Femenino	4	2	90
36	22	Masculino	8	2	85
37	20	Masculino	6	4	86
38	22	Femenino	8	4	90
39	19	Masculino	2	1	70
40	18	Masculino	2	1	60
41	18	Masculino	2	2	78
42	21	Femenino	8	2	9
43	19	Femenino	5	8	90
44	19	Masculino	4	2	80
45	19	Femenino	5	8	100
46	21	Femenino	8	2	90
47	22	Femenino	8	1	85
48	20	Prefiero no decirlo	5	2	90
49	20	Femenino	6	2	80

#1. Establecer variables

```
x= df ["Horas_estudiadas"]
```

```
y= df ["Calificacion_obtenida"]
```

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 50 entries, 0 to 49
```

```
Data columns (total 5 columns):
```

```
#   Column              Non-Null Count  Dtype
---  -
0   Edad                50 non-null  int64
1   Sexo                50 non-null  object
2   Semestre_actual     50 non-null  int64
3   Horas_estudiadas    50 non-null  int64
4   Calificacion_obtenida 50 non-null  int64
```

```
dtypes: int64(4), object(1)
```

```
memory usage: 2.1+ KB
```

```
df.describe()
```

	Edad	Semestre_actual	Horas_estudiadas	Calificacion_obtenida
count	50.000000	50.000000	50.000000	50.000000
mean	20.160000	5.560000	3.020000	77.260000
std	2.518179	2.101117	1.93243	24.679836
min	14.000000	1.000000	1.000000	8.000000
25%	19.000000	4.000000	2.000000	78.250000
50%	20.000000	6.000000	2.000000	85.000000
75%	22.000000	7.000000	4.000000	90.000000
max	27.000000	9.000000	8.000000	100.000000

#2. Diagrama de dispersión

```
from matplotlib.lines import lineStyles
```

```
import matplotlib.pyplot as plt
```

```
#configuración general
```

```
plt.figure(
    figsize=(6,4), #tamaño (ancho, alto)
    dpi=100        #resolución
)
```

```
#Gráfico de dispersión
```

```
plt.scatter(
    x,y,
    marker="o",
    color="pink",
    edgecolor="blue", #color de borde
    alpha=0.9, #transparencia
)
```

```

        s=60, #tamaño de punto
        label="Calificacion_obtenida" #etiqueta
    )
    #plt.plot(
    #    x,y_calculada,
    #    marker="o",
    #    linewidth=2.2,
    #    linestyle="--",
    #    markersize=5,
    #markerfacecolor="white",
    #markeredgecolor="black",
    #label="Promedio_final"


    #)

    #Título
    plt.title(
        "Gráfico de dispersión",
        fontsize=12, #tamaño de fuente
        fontweight="bold" #bold:negritas
    )
    #Etiquetas eje x
    plt.xlabel(
        "Horas_estudiadas",
        fontsize=10,
    )
    #Etiqueta eje y
    plt.ylabel(
        "Calificacion_obtenida",
        fontsize=10
    )
    #tamaño de los ticks
    plt.xticks(fontsize=10)
    plt.yticks(fontsize=10)

    #Márgenes
    plt.margins(x=0.05,y=0.05)
    plt.gca().spines[["top","right"]].set_visible(False)

    plt.grid(
        visible=True,
        linestyle="--",
        linewidth=0.7, #ancho de línea
        alpha=0.5, #transparencia
        color="black"
    )
    #Leyenda
    plt.legend(
        fontsize=10,
        loc="best",
        frameon=False
        #bbox_to_anchor=(0.5,-0.15)
    )
    #Guardar imagen
    plt.savefig(
        "Dispersión",
        bbox_inches="tight"
    )

```



```
#4. Calcula el coeficiente de correlación e interpreta el resultado
from scipy.stats import pearsonr
r, valor_p=pearsonr(x,y) #p es de prueba de hipótesis
                        # Ho: P=0 No hay correlación (el cambio en una
                        #    variable está vinculado con el cambio en otra variable)
                        # H1: P!=0 Sí hay correlación
print(f"coeficiente de correlación (r):{r:0.4f}")
print(f"valor_p:{valor_p:0.4f}")

coeficiente de correlación (r):0.0602
valor_p:0.6778
```

4. Interpreta el resultado del coeficiente de correlación

- $r = 0.0602 \rightarrow$ no hay una correlación lineal significativa.
- El valor $p = 0.6778 (> 0.05)$, por lo tanto no se rechaza H_0 .
- No existe evidencia suficiente para afirmar que hay correlación entre las horas de estudio y la calificación obtenida.
- La relación es positiva, pero **muy débil**.

```
#5 Calcule el coeficiente de determinación e interprete el resultado.  $\theta = r^2$ 
print(f"coeficiente de determinación:{r**2:0.4f}")
```

coeficiente de determinación:0.0036

####5. Interprete el resultado del coeficiente de determinación

- $r^2 = 0.0036$
- El modelo explica a un 36% la variación de la variable dependiente.

```
#6. Obtenga la recta de regresión ajustada y grafíquelo sobre el gráfico de
dispersión.
```

```
import statsmodels.api as sm
x_constante=sm.add_constant(x)
modelo=sm.OLS(y,x_constante).fit()
y_calculada=modelo.predict(x_constante)
modelo.params
```

	0	
const	74.937152	
Horas_estudiadas	0.769155	

dtype: float64

```
#6. grafíquelo sobre el gráfico de dispersión.
```

```
from matplotlib.lines import lineStyles
import matplotlib.pyplot as plt
#configuración general
plt.figure(
    figsize=(6,4), #tamaño (ancho, alto)
    dpi=100        #resolución
)
#Gráfico de dispersión
plt.scatter(
```

```

        x,y,
        marker="o",
        color="yellow",
        edgecolor="black", #color de borde
        alpha=0.9, #transparencia
        s=60, #tamaño de punto
        label="Calificaciones_obtenidas" #etiqueta
    )

plt.plot(
    x,y_calculada,
    marker="o",
    color="blue",
    linewidth=2.2,
    linestyle="--",
    markersize=5,
    markerfacecolor="white",
    markeredgecolor="black",
    label="recta de regresión"

)

#Título
plt.title(
    "Gráfico de dispersión",
    fontsize=12, #tamaño de fuente
    fontweight="bold" #bold:negritas
)

#Etiquetas eje x
plt.xlabel(
    "Horas_estudio",
    fontsize=10,
)

#Etiqueta eje y
plt.ylabel(
    "Calificaciones_obtenidas",
    fontsize=10
)

#tamaño de los ticks
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)


#Márgenes
plt.margins(x=0.05,y=0.05)
plt.gca().spines[["top", "right"]].set_visible(False)

plt.grid(
    visible=True,
    linestyle="--",
    linewidth=0.7, #ancho de línea
    alpha=0.5, #transparencia
    color="black"
)

#Leyenda
plt.legend(
    fontsize=10,
    loc="best",
    frameon=False
    #bbox_to_anchor=(0.5,-0.15)
)

#Guardar imagen
plt.savefig(
    "Dispersión",
    bbox_inches="tight"
)

```



#7. Obtenga un intervalo de confianza del 95% para la pendiente de la recta de

#regresión ajustada (b1)

modelo.conf_int(alpha = 0.05)

	0	1
const	61.711184	88.163119
Horas_estudiadas	-2.930507	4.468817

#8. Calcule los residuales y trace un nuevo gráfico de dispersión.

#Comente, ¿Parece que se verifican los supuestos?

```
residuales=modelo.resid

#Gráfico de dispersión
plt.scatter(
    x,residuales,
    marker="o",
    color="pink",
    edgecolor="purple", #color de borde
    alpha=0.9, #transparencia
    s=60, #tamaño de punto
    label="Calificaciones_obtenidas" #etiqueta
)

#Título
plt.title(
    "Gráfico de residuales",
    fontsize=12, #tamaño de fuente
    fontweight="bold" #bold:negritas
)

#Etiquetas eje x
plt.xlabel(
    "Horas_estudio",
    fontsize=10,
)

#Etiqueta eje y
plt.ylabel(
    "Calificaciones_obtenidas",
    fontsize=10
)

#tamaño de los ticks
plt.xticks(fontsize=10)
plt.yticks(fontsize=10)

#Márgenes
plt.margins(x=0.05,y=0.05)
plt.gca().spines[["top","right"]].set_visible(False)

plt.grid(
    visible=True,
    linestyle="--",
    linewidth=0.7, #ancho de línea

```

```


    alpha=0.2, #transparencia
    color="black"
)
#Leyenda
plt.legend(
    fontsize=10,
    loc="best",
    frameon=False
    #bbox_to_anchor=(0.5,-0.15)
)
#Guardar imagen
plt.savefig(
    "Dispersión",
    bbox_inches="tight"
)

plt.axhline(y=0, color="gray", linestyle="--") #Línea horizontal

#Parece que siguen el supuesto de Linealidad

<matplotlib.lines.Line2D at 0x7daa41834b00>

```



```

#9 Test de Shapiro
from scipy.stats import shapiro
estadistico, valor_p=shapiro(residuales)
print(f"Valor_p: {valor_p:0.4f}")
# Ho: Los datos siguen una distribución normal
# H1: Los datos NO siguen una distribución normal

```

Valor_p: 0.0000

####9. Comente el resultado del **Test de Shapiro**

Como el valor p es menor al nivel de significancia ($0.0000 < 0.05$), se rechaza la hipótesis nula (H_0).

Por lo tanto, los datos **no siguen una distribución normal**.

Nota: El test de Shapiro-Wilk es muy sensible cuando el tamaño de la muestra es mayor a 30. Por esta razón, además del resultado de la prueba, revisaremos el **histograma** y el **gráfico Q-Q (Q-Q Plot)** para confirmar visualmente si los datos presentan o no un comportamiento cercano a una distribución normal.

```

#Histograma y Q-Q plot
from scipy.stats import shapiro
import matplotlib.pyplot as plt
import seaborn as sns



```

```

# Visualización: Q-Q plot
sm.qqplot(residuales, line='s')
plt.title("Q-Q plot de residuos")
plt.show()

```

```
# Histograma
sns.histplot(residuales, kde=True)
plt.title("Histograma de residuos")
plt.show()
```



Q-Q Plot

- Como se puede observar, los puntos no siguen completamente la línea de referencia, especialmente en los extremos.
- Se presentan desviaciones importantes respecto a la línea roja, lo que indica que los residuales no siguen una distribución normal.
- Esto coincide con el resultado obtenido en el Test de Shapiro, donde se rechazó la hipótesis de normalidad.

Histograma

- El histograma no presenta una forma de campana ni una distribución simétrica.
- Se observa la presencia de valores atípicos, principalmente hacia el lado izquierdo, lo que afecta la distribución de los residuales.
- Con base en el histograma, se puede concluir que los residuales no siguen una distribución normal.

```
#10. Test de Breusch-Pagan
from statsmodels.stats.api import het_breuschpagan
estadistico_1, valor_p_1, estadistico_2, valor_p_2 =
    het_breuschpagan(residuales, x_constante)
print(f"valor_p:{valor_p_1:0.4f}")
```


H0: No hay heterocedasticidad (varianza uniforme)
 # H1: Hay heterocedasticidad (varianza no uniforme)

valor_p:0.5867

10. Comente el resultado del Test de Breusch-Pagan

- Como el valor p es mayor al nivel de significancia, $0.5867 > 0.05$.
- Entonces, no se rechaza la hipótesis nula (H_0).
- Por lo tanto, no existe evidencia de heterocedasticidad; es decir, los datos presentan homocedasticidad.
- La varianza de los residuales puede considerarse constante a lo largo del modelo.

#11. Utiliza la recta de regresión para interpolar dos valores y extrapolar uno.

#Comenta estos resultados.
 df.describe()

	Edad	Semestre_actual	Horas_estudiadas	Calificacion_obtenida
count	50.000000	50.000000	50.000000	50.000000
mean	20.160000	5.560000	3.020000	77.260000
std	2.518179	2.101117	1.93243	24.679836
min	14.000000	1.000000	1.000000	8.000000
25%	19.000000	4.000000	2.000000	78.250000
50%	20.000000	6.000000	2.000000	85.000000
75%	22.000000	7.000000	4.000000	90.000000
max	27.000000	9.000000	8.000000	100.000000

#11
 modelo.predict([1,1.9])

array([76.39854629])

#11
 modelo.predict([1,1])

array([75.7063067])

#11
 modelo.predict([1,0.3])

array([75.16789813])

11. Resultados

- **Interpolando:**
 - $f(1.9) = 76.40$
 - Se estima que un estudiante que estudia **1.9 horas** obtendrá una calificación aproximada de **76.40**.
- **Extrapolando:**
 - $f(0.3) = 75.17$
 - Se estima que un estudiante que estudia **0.3 horas** obtendrá una calificación aproximada de **75.17**.

#12. Realice una tabla ANOVA e interprete el resultado.

```
from statsmodels.formula.api import ols
# y ~ x
modelo_lineal=ols("Calificacion_obtenida~Horas_estudiadas", data=df).fit()
tabla_anova=sm.stats.anova_lm(modelo_lineal)
tabla_anova
```

	df	sum_sq	mean_sq	F	PR(>F)
Horas_estudiadas	1.0	108.250889	108.250889	0.174731	0.677805
Residual	48.0	29737.369111	619.528523	NaN	NaN

12. Interprete el resultado de la Tabla ANOVA

- H_0 : La variable independiente (Horas_estudiadas) no explica la variable dependiente (Calificacion_obtenida).
- H_1 : Sí existe una relación lineal entre las variables.
- El valor p = 0.6778.

- Valor $p > 0.05$.
- No se rechaza H_0 .
- Por lo tanto, no existe evidencia suficiente para afirmar que hay una relación lineal significativa entre las horas estudiadas y la calificación obtenida.
- El modelo de regresión lineal no es estadísticamente significativo.